

Hurtownie danych i systemy Business Intelligence

Analiza danych z platformy Airbnb w hurtowni
danych z wykorzystaniem danych zewnętrznych

Natalia Choszczyk | Filip Langiewicz

nr indeksu 327267 | nr indeksu 327293

Politechnika Warszawska

Wydział Matematyki i Nauk Informacyjnych

11 czerwca 2025

Spis treści

1. Temat i cel projektu	4
2. Diagram oraz opis architektury rozwiązania procesu ETL	5
2.1. Opis ogólny	5
2.2. Struktura pakietu	6
2.2.1. Główne zadania (Tasks)	6
2.2.2. Źródła danych (Connection Managers)	7
2.2.3. Zmienne pakietu	7
2.3. Opis szczegółowy	7
2.4. Sposoby transformacji i integracji danych	11
2.4.1. Transformacja danych	11
2.4.2. Integracja danych	12
2.4.3. Podsumowanie	12
2.5. Uwagi końcowe	12
3. Wykorzystywane zbiory danych	13
3.1. Platforma Airbnb	13
3.2. Prognoza pogody	13
4. Model fizyczny hurtowni danych	14
4.1. Tabele faktów	15
4.2. Tabele wymiarów	15
4.3. Technika SCD2	15
5. Kluczowe miary, atrybuty oraz hierarchie w modelu	20
6. Warstwa raportowa	22
6.1. Dostęp do danych	22
6.2. Model biznesowy danych	22
6.3. Hierarchie	22
6.4. Transformacje w obrębie warstwy raportowej	22
6.5. Funkcjonalności raportowe	23

7. Raporty dla użytkowników	24
7.1. Struktura raportu	24
7.2. Interaktywność raportu	30
8. Wykonane testy	31
8.1. Zasilanie pustej bazy danych	31
8.2. Wykonywanie procesu ETL przy braku zmian w źródle danych	32
8.3. Wykonywanie procesu ETL przy obecnych zmianach w źródle danych - nowe miasta	33
8.4. Dodanie nowej obserwacji	34
8.5. Aktualizacja obserwacji w <code>Dim_Property</code> - test działania SCD2	36
8.6. Brak połączenia z <code>WeatherAPI</code> - trafienie w czas niedostępności	37
8.7. Ładowanie danych do narzędzia BI	38
8.8. End-to-end test	40
9. Podsumowanie rezultatów projektu	42
10. Podział pracy w zespole	43

1. Temat i cel projektu

Analiza danych z platformy Airbnb w hurtowni danych z wykorzystaniem zewnętrznych danych pogodowych.

Celem projektu jest analiza wpływu czynników zewnętrznych na to, w jaki sposób użytkownicy rezerwują noclegi na platformie Airbnb. Te czynniki to między innymi prognozowane warunki pogodowe, opinie i oceny użytkowników, czy dostępność opcji noclegowych w danym rejonie. Celem projektu jest zrozumienie, w jaki sposób te zmienne wpływają na cenę wynajmu, ale też dostępność i preferencje użytkowników.


Projekt umożliwi użytkownikom platformy Airbnb lepsze i bardziej świadome planowanie podróży, w oparciu o rzeczywiste dane, co może w przyszłości pozytywnie wpłynąć na oszczędność pieniędzy oraz ogólną satysfakcję użytkownika. Rozwiązanie umożliwi znalezienie najbardziej opłacalnych terminów wyjazdów, co rozumiemy jako najlepszą pogodę i najniższe ceny przy dobrych warunkach noclegowych. Zbadane zostaną również interakcje między poszczególnymi czynnikami, co pozwoli na zaobserwowanie ukrytych zależności w danych.

2. Diagram oraz opis architektury rozwiązania procesu ETL

2.1. Opis ogólny

Pakiet SSIS o nazwie **Airbnb ETL** służy do integracji danych pochodzących z różnych źródeł, głównie plików płaskich (CSV) oraz danych pogodowych pobieranych z zewnętrznego źródła. Przetworzone dane są ładowane do hurtowni danych w bazie `localhost.AIRBNB_star_dwh`.

Poniższy diagram (rysunek 2.1) przedstawia ogólną architekturę zaprojektowanego procesu ETL, którego celem jest pobieranie, przetwarzanie i ładowanie danych z platformy Airbnb oraz z API pogodowego do hurtowni danych. Proces ten został zorganizowany w logiczne kroki, które umożliwiają modularne przetwarzanie poszczególnych aspektów danych: ofert (listings), recenzji (reviews) oraz kalendarza dostępności (calendar).



Rysunek 2.1: Model procesu ETL

2.2. Struktura pakietu

2.2.1. Główne zadania (Tasks)

Pakiet zawiera następujące główne komponenty (Executable Tasks), przedstawione w tabeli 2.1.

Nazwa zadania	Typ zadania	Rola
Airbnb ETL	Microsoft.Pipeline	Główna sekwencja kontrolna
Fetch Airbnb Data	Microsoft.ExecuteProcess	Wywołanie zewnętrznego skryptu Pythonowego, który pobiera dane dotyczące ofert Airbnb
GET Weather	Microsoft.ExecuteProcess	Wywołanie skryptu Pythonowego, który pozyskuje dane pogodowe z API
DFT_Load_Weather	Microsoft.Pipeline	Data Flow Task – ładowanie danych pogodowych do hurtowni
Script Task (x3)	Microsoft.ScriptTask	Przetwarzanie nazw plików w celu wyciągnięcia informacji o dacie, mieście, regionie i państwie
Foreach Loop Listings	-	Iteracja po plikach z nieruchomościami do wynajęcia
DFT_Load_Listings	Microsoft.Pipeline	Ładowanie danych nieruchomości do tabeli Dim_Property
Foreach Loop Reviews	-	Iteracja po plikach z recenzjami
DFT_Load_Reviews	Microsoft.Pipeline	Ładowanie danych recenzji do tabeli Dim_Reviews
Foreach Loop Calendar	-	Pętla iterująca po plikach z ofertami
DFT_Load_Calendar	Microsoft.Pipeline	Ładowanie danych ofert do tabeli Dim_Offers

Tabela 2.1: Główne komponenty pakietu

2.3. OPIS SZCZEGÓŁOWY

2.2.2. Źródła danych (Connection Managers)

Wykorzystywane źródła danych wymienione są w tabeli 2.2.

Nazwa połączenia	Typ źródła
WeatherFileConnection	FLATFILE - plik CSV
ListingsFileConnection	FLATFILE - plik CSV
ReviewFileConnection	FLATFILE - plik CSV
CalendarFileConnection	FLATFILE - plik CSV
localhost.AIRBNB_star_dwh	OLEDB - hurtownia danych w SQL Server

Tabela 2.2: Wykorzystywane źródła danych

2.2.3. Zmienne pakietu

Pakiet wykorzystuje zmienne obliczane w skryptach pomocniczych, wymienione w tabeli 2.3.

Nazwa zmiennej	Typ danych
City	String
Region	String
Country	String
CurrentFilePath	String
FileType	String
ScrapeDate	Int64

Tabela 2.3: Pomocnicze zmienne

2.3. Opis szczegółowy


Proces ETL rozpoczyna się od zadania głównego **Airbnb ETL**, które koordynuje pobieranie i dalsze przetwarzanie danych. W ramach tego procesu realizowane są następujące kroki:

- **Fetch Airbnb Data** – inicjalne pobranie danych ze źródła za pomocą skryptu Pythonowego.

W tym celu pobierane jest źródło strony <http://insideairbnb.com/get-the-data/index.html>, a następnie analizowane pod względem wystąpień linków do pobierania plików typu .csv.gz. Pliki te są otwierane i wypakowywane do prostych formatów typu .csv. Skrypt w trakcie działania wybiera również z każdego pliku odpowiednie kolumny i tylko je zapisuje

do plików w folderze docelowym `airbnb_data\NEW`. Działanie takie jest wymuszone ograniczeniami programu Visual Studio, który wczytuje dane po indeksach kolumn, a nie po ich nazwach. W momencie, gdy pliki różnią się liczbą kolumn, program nie potrafi sobie poradzić z takim, trywialnym by się wydawało, zadaniem.

- **GET Weather** – integracja z serwisem pogodowym w celu wzbogacenia danych kalendarza o informacje pogodowe, co może mieć wpływ na dostępność i atrakcyjność ofert. Ponownie wywoływany jest skrypt w Pythonie, który, łącząc się API pogodowym, pobiera odpowiednie dane i zapisuje do pliku `weather.csv` w folderze docelowym `airbnb_data\WEATHER`.
- **DFT_Load_Weather** – zasilenie hurtowni (tabeli `Dim_Reviews`) danymi z pliku `weather.csv`, który utworzony został w poprzednim kroku. Dane zaczytywane są najpierw z pliku `weather.csv`, a następnie wykonywany jest **Lookup**, który sprawdza, czy dane dla danej lokalizacji i danego dnia są już w bazie. Jeżeli nie, są one wstawiane do tabeli pogodowej. W przypadku, gdy klucz główny jest już obecny, następuje sprawdzenie, czy obecne dane są nowsze niż dane występujące aktualnie w hurtowni. Jeżeli tak, stare dane są aktualizowane, w przeciwnym przypadku operacja jest pomijana. Schemat procesu ukazany jest na rysunku 2.2.




Rysunek 2.2: Data Flow Load Weather

- **Script Task (x3)** – wyodrębnia z nazwy obecnie przetwarzanego pliku datę, państwo, region oraz miasto, a następnie przypisuje do zmiennych systemowych w celu późniejszego wykorzystania.
- **Foreach Loop Listings/Reviews/Calendar** – iteracyjne przetwarzanie plików `.csv` z folderu `airbnb_data\NEW` dotyczących nieruchomości do wynajęcia/recenzji/ofert. W ramach pętli dla każdego pliku wykonywany jest skrypt opisany powy-

2.3. OPIS SZCZEGÓŁOWY

żej, a następnie dane są pobierane, transformowane i ładowane do bazy za pomocą DFT_Load_Listings/DFT_Load_Reviews/DFT_Load_Calendar, które są omówione poniżej.


- **DFT_Load_Listings** – zadanie to realizuje proces wczytywania, transformacji i ładowania danych dotyczących ofert Airbnb do hurtowni danych, do tabeli Dim_Property. Proces rozpoczyna się od załadowania danych z pliku *_listings.csv. W dalszym etapie, przy użyciu komponentu **Derived Column**, do danych dodawane są dodatkowe informacje, takie jak data pobrania, lokalizacja (na podstawie nazwy pliku), oznaczenie aktywności rekordu oraz zakres jego ważności – z bieżącą datą jako **validFrom** i wartością 99991231 jako **validTo**, reprezentującą rekord aktywny. W ramach transformacji dokonywana jest również konwersja typów danych, tak aby odpowiadały one strukturze modelu hurtowni danych. W tabeli Dim_Property zaimplementowano mechanizm śledzenia zmian typu SCD2 (Slowly Changing Dimension Type 2). W celu jego obsługi zastosowano komponent **Lookup**, który sprawdza, czy dany obiekt już istnieje w bazie. Jeżeli nie, rekord jest przesyłany dalej jako nowy. W przypadku istnienia rekordu następuje porównanie danych w celu wykrycia ewentualnych zmian. Jeśli zostaną one stwierdzone, dotychczasowy rekord jest oznaczany jako nieaktywny poprzez aktualizację pola **validTo** na datę bieżącą oraz pola **isActive** na 'NO', natomiast zmodyfikowana wersja zostaje przygotowana jako nowy wpis. Zarówno nowe, jak i zmienione rekordy są następnie łączone w komponencie **Union**, a całość trafia do hurtowni danych jako aktualna wersja wymiaru ofert. Schemat procesu ukazany jest na rysunku 2.3.



Rysunek 2.3: Data Flow Load Listings


- **DFT_Load_Reviews** – zadanie to odpowiada za proces wczytywania, transformacji i łado-

wania danych dotyczących recenzji ofert Airbnb do hurtowni danych, do tabeli **Fact_Reviews**. Przetwarzanie rozpoczyna się od załadowania danych z pliku ***_reviews.csv**. W kolejnych etapach, z wykorzystaniem komponentu **Derived Column**, do danych dodawane są informacje uzupełniające, takie jak data pobrania oraz lokalizacja, wyodrębniana na podstawie nazwy pliku. W dalszej części procesu przeprowadzana jest konwersja typów danych w celu ich dostosowania do struktury modelu hurtowni. Następnie wykonywany jest komponent **Lookup**, którego zadaniem jest przypisanie odpowiednich kluczy głównych z tabeli **Dim_Property** – uwzględniając możliwość ich zmiany w wyniku wcześniejszych aktualizacji danych wymiaru. W kolejnym kroku stosowany jest dodatkowy **Lookup**, który weryfikuje, czy dany rekord recenzji nie występuje już w tabeli faktów. Rekord zostaje zapisany do hurtowni wyłącznie w przypadku, gdy nie został wcześniej zarejestrowany. Schemat procesu ukazany jest na rysunku 2.4.



Rysunek 2.4: Data Flow Load Reviews

- **DFT_Load_Calendar** – zadanie to odpowiada za proces wczytywania, transformacji i ładowania danych dotyczących ofert Airbnb do hurtowni danych, do tabeli **Fact_Offers**. Całość analogiczna jest do komponentu **DFT_Load_Reviews**. Schemat procesu ukazany jest na rysunku 2.5.



Rysunek 2.5: Data Flow Load Calendar

2.4. Sposoby transformacji i integracji danych

Proces ETL zaprojektowany dla projektu integracji danych z platformy **Airbnb** obejmuje szereg operacji transformacyjnych i integracyjnych, których celem jest przygotowanie danych źródłowych do dalszej analizy w hurtowni danych **AIRBNB_star_dwh** (Microsoft SQL Server). Transformacje mają zapewnić wysoką jakość, spójność i jednolitą strukturę danych, natomiast integracja – wydajny dostęp do informacji w modelu gwiazdy.

2.4.1. Transformacja danych

Transformacje realizowane są głównie w obrębie pętli **Foreach Loop** odpowiadających poszczególnym domenom danych (`listings/reviews/calendar`).

1. Uzupełnianie braków danych

Wartości **NULL** są zamieniane na:

- YES/NO – dla pól logicznych (np. `host_is_superhost`),
- 0 – dla pól liczbowych,
- pusty łańcuch znaków – dla pól tekstowych.

2. Standaryzacja formatów

- Pola logiczne `t/f` → YES/NO.
- Pola walutowe (np. `price`) – usunięcie symbolu waluty, zamiana przecinka na kropkę i konwersja do **FLOAT**.
- Konwersja wszystkich łańcuchów do kodowania **Unicode** (UTF-8).

3. Ujednolicenie długości ciągów znaków

Wartości tekstowe są mapowane do długości zdefiniowanej w schemacie (np. `NVARCHAR(255)`).

4. Dodanie kolumn technicznych

Każdy rekord otrzymuje metadane:

<code>scrape_date</code>	data scrapowania pliku,
<code>country</code>	kraj,
<code>region</code>	region administracyjny,
<code>city</code>	miasto.

Dzięki temu możliwa jest analiza historyczna i segmentacja geograficzna.

2.4.2. Integracja danych

1. Kolejność ładowania

Najpierw ładowane są wymiary (ang. *dimensions*), a następnie fakty (ang. *facts*), co minimalizuje ryzyko naruszenia kluczy obcych.

2.4.3. Podsumowanie

Zaprojektowane transformacje gwarantują spójność typów danych, eliminację błędów oraz wprowadzenie jednolitych standardów zapisu. Efektem integracji jest hurtownia oparta na schemacie gwiazdy, umożliwiająca szybkie i elastyczne raportowanie informacji o ofertach, recenzjach, cenach i dostępności w różnych przekrojach czasowych i geograficznych.

2.5. Uwagi końcowe

Proces jest modularny i elastyczny dzięki użyciu zmiennych, pętli oraz zewnętrznych skryptów. Wszystkie dane są ładowane do bazy OLEDB, co pozwala na dalsze analizy w kontekście hurtowni danych.

3. Wykorzystywane zbiory danych

3.1. Platforma Airbnb

Dane z platformy Airbnb dostępne są na stronie <https://insideairbnb.com/>. Dane są podzielone na regiony. Dla każdego regionu korzystamy z trzech plików `.csv`:


- `calendar.csv.gz` - opisuje ceny i dostępność danego miejsca w poszczególnych dniach,
- `listings.csv.gz` - dotyczy ofert noclegów,
- `reviews.csv.gz` - zawiera opinie wystawione dla poszczególnych obiektów.

Dane pochodzą z okresu jednego roku w przód, dotyczą ofert w przyszłości, czyli tych, które widzimy w serwisie Airbnb na najbliższy rok. Dane są aktualizowane nieregularnie - różnie dla poszczególnych regionów, jednak średnio nowe dane otrzymujemy co 3 miesiące. Dostęp do danych uzyskujemy poprzez scrapowanie strony skryptem Pythonowym, który pobiera i zapisuje te dane.

3.2. Prognoza pogody

Dane pogodowe uzyskujemy ze strony <https://www.weatherapi.com/>. Pozyskujemy w ten sposób prognozę pogody na 300 dni do przodu. Dane są dostępne dla konkretnej lokalizacji na podstawie współrzędnych geograficznych lub nazwy miasta. Prognoza jest regularnie aktualizowana - co 4-6 godzin. Dostęp do API strony uzyskujemy po zalogowaniu się na stronę i wygenerowaniu klucza dostępu API. Dane pobieramy z API skryptem Pythonowym i następnie są one zapisywane do pliku `weather.csv`.

4. Model fizyczny hurtowni danych



Rysunek 4.1: Model hurtowni danych oparty na danych z Airbnb

4.1. Tabele faktów

Powyższy rysunek 4.1 przedstawia model hurtowni danych bazujący na schemacie gwiazdy. Model składa się z dwóch tabel faktów oraz trzech tabel wymiarów.

4.1. Tabele faktów

- **Fact_Offers** – zawiera informacje dotyczące ofert wynajmu na dany dzień, takie jak cena, dostępność, liczba minimalnych i maksymalnych nocy, czy lokalizacja. Połączona z tabelami wymiarów: **Dim_Property**, **Dim_Weather**, **Dim_Date**.
- **Fact_Review** – zawiera dane dotyczące recenzji wystawionych przez użytkowników, w tym datę wystawienia, dane wystawiającego oraz odniesienie do obiektu. Połączona z: **Dim_Property**, **Dim_Date**.

4.2. Tabele wymiarów

- **Dim_Property** – dotyczy danych, które opisują dane miejsca noclegowe i nieruchomości. Zawiera dużo szczegółowych informacji na temat wynajmowanego miejsca. Są to między innymi informacje o gospodarzu, typie nieruchomości, liczbie pokoi, lokalizacji, średnich opiniach itp.
- **Dim_Weather** – opisuje pogodę dla danej lokalizacji i daty. Przechowuje dane takie jak temperatura, opady, godzina wschodu i zachodu słońca.
- **Dim_Date** – standardowa tabela kalendarza zawierająca dokładne informacje dotyczące daty: dzień tygodnia, miesiąc, kwartał, czy dzień wolny od pracy.

4.3. Technika SCD2

Dla tabeli **Dim_Property** została zastosowana technika SCD2, która umożliwia śledzenie historii zmian w hurtowni. W tym celu kluczem głównym tabeli jest **property_sk**, który jest kluczem zastępczym. Każda zmiana atrybutów nieruchomości skutkuje dodaniem nowego rekordu z nowym **property_sk**. Tabela zawiera dodatkowe kolumny:

- **isActive** - informuje, czy rekord jest aktualny,
- **validFrom** - data rozpoczęcia ważności rekordu
- **validTo** - data zakończenia ważności rekordu.

Szczegółowe informacje o bazie danych przedstawione są w tabelach 4.1 - 4.5.

Kolumna	Typ danych	NULL	Relacja
property_sk	bigint	Nie	PK
property_id	bigint	Nie	
last_scraped	date	Nie	
property_name	nvarchar(255)	Nie	
host_id	bigint	Nie	
host_name	nvarchar(100)	Nie	
host_since	date	Nie	
host_response_time	nvarchar(50)	Nie	
host_response_rate	float	Nie	
host_acceptance_rate	float	Nie	
host_is_superhost	nvarchar(3)	Nie	
host_listings_count	int	Nie	
host_total_listings_count	int	Nie	
host_identity_verified	nvarchar(3)	Nie	
latitude	float	Nie	
longitude	float	Nie	
property_type	nvarchar(100)	Nie	
room_type	nvarchar(100)	Nie	
accommodates	int	Nie	
bathrooms	float	Nie	
bedrooms	int	Nie	
beds	int	Nie	
price	float	Nie	
minimum_nights	int	Nie	
maximum_nights	int	Nie	
has_availability	nvarchar(3)	Nie	
availability_30	int	Nie	
availability_60	int	Nie	
availability_90	int	Nie	
availability_365	int	Nie	
number_of_reviews	int	Nie	

4.3. TECHNIKA SCD2

number_of_reviews_ltm	int	Nie	
number_of_reviews_l30d	int	Nie	
review_scores_rating	float	Nie	
review_scores_accuracy	float	Nie	
review_scores_cleanliness	float	Nie	
review_scores_checkin	float	Nie	
review_scores_communication	float	Nie	
review_scores_location	float	Nie	
review_scores_value	float	Nie	
instant_bookable	nvarchar(3)	Nie	
calculated_host_listings_count	int	Nie	
calculated_host_listings_count_entire_homes	int	Nie	
calculated_host_listings_count_private_rooms	int	Nie	
calculated_host_listings_count_shared_rooms	int	Nie	
reviews_per_month	float	Nie	
scrape_date	int	Nie	
country	nvarchar(100)	Nie	
region	nvarchar(100)	Nie	
city	nvarchar(100)	Nie	
isActive	nvarchar(3)	Nie	
validFrom	bigint	Nie	
validTo	bigint	Nie	

Tabela 4.1: Dim_Property

Kolumna	Typ danych	NULL	Relacja
date	date	Nie	PK
Day	tinyint	Nie	
DaySuffix	char(2)	Nie	
Weekday	tinyint	Nie	
WeekDayName	varchar(10)	Nie	
IsWeekend	bit	Nie	
IsHoliday	bit	Nie	
DOWInMonth	tinyint	Nie	

DayOfYear	smallint	Nie	
WeekOfMonth	tinyint	Nie	
WeekOfYear	tinyint	Nie	
ISOWeekOfYear	tinyint	Nie	
Month	tinyint	Nie	
MonthName	varchar(10)	Nie	
Quarter	tinyint	Nie	
QuarterName	varchar(6)	Nie	
Year	int	Nie	
MMYYYY	char(6)	Nie	
MonthYear	char(7)	Nie	
FirstDayOfMonth	date	Nie	
LastDayOfMonth	date	Nie	
FirstDayOfQuarter	date	Nie	
LastDayOfQuarter	date	Nie	
FirstDayOfYear	date	Nie	
LastDayOfYear	date	Nie	
HolidayText	nvarchar(100)	Tak	

Tabela 4.2: Dim_Date

Kolumna	Typ danych	NULL	Relacja
weather_id	nvarchar(50)	Nie	PK
date	date	Nie	
location_name	nvarchar(100)	Nie	
avg_temp	float	Nie	
max_temp	float	Nie	
min_temp	float	Nie	
daily_will_it_rain	nvarchar(3)	Nie	
daily_will_it_snow	nvarchar(3)	Nie	
daily_chance_of_rain	float	Nie	
daily_chance_of_snow	float	Nie	
sunrise	time(7)	Nie	
sunset	time(7)	Nie	

4.3. TECHNIKA SCD2

last_modified_date	date	Nie	
--------------------	------	-----	--

Tabela 4.3: Dim_Weather

Kolumna	Typ danych	NULL	Relacja
offer_id	bigint (IDENTITY)	Nie	PK
property_id	bigint	Nie	FK → Dim_Property(property_sk)
offer_date	date	Nie	FK → Dim_Date(date)
available	nvarchar(3)	Nie	
price	money	Nie	
minimum_nights	float	Nie	
maximum_nights	float	Nie	
weather_id	nvarchar(50)	Nie	FK → Dim_Weather(weather_id)
scrape_date	int	Nie	
country	nvarchar(100)	Nie	
region	nvarchar(100)	Nie	
city	nvarchar(100)	Nie	

Tabela 4.4: Fact_Offers

Kolumna	Typ danych	NULL	Relacja
review_id	bigint (IDENTITY)	Nie	PK
property_id	bigint	Nie	FK → Dim_Property(property_sk)
date	date	Nie	FK → Dim_Date(date)
reviewer_name	nvarchar(100)	Nie	
reviewer_id	bigint	Nie	
scrape_date	int	Nie	
country	nvarchar(100)	Nie	
region	nvarchar(100)	Nie	
city	nvarchar(100)	Nie	

Tabela 4.5: Fact_Review

5. Kluczowe miary, atrybuty oraz hierarchie w modelu

Najważniejsze miary wykorzystywane do analiz znajdują się w tabelach faktów, a opisy i atrybuty danych przechowywane są w tabelach wymiarów.

Miary (tabele faktów)

- **Fact_Offers**
 - `price` – cena oferty w danym dniu,
 - `available` – dostępność oferty,
 - `minimum_nights`, `maximum_nights` – minimalna i maksymalna długość pobytu.
- **Fact_Review**
 - zagregowana liczba uzyskanych opinii.

Atrybuty (tabele wymiarów)

- **Dim_Property**
 - `property_type`, `room_type`, `accommodates`, `price`, `bedrooms`, `beds`, `bathrooms` - podstawowe informacje na temat wynajmowanego miejsca,
 - `host_is_superhost`, `host_response_rate` itd. - informacje na temat właściciela obiektu,
 - `latitude`, `longitude`, `country`, `region`, `city` - dane na temat lokalizacji wynajmowanego miejsca,
 - `review_scores_rating`, `reviews_per_month`, itd. - dane dotyczące ocen obiektu.
- **Dim_Date**
 - `year`, `quarter`, `month`, `day`, `is_weekend` - te i wiele innych parametrów dotyczących daty.

- `Dim_Weather`

- `min_temp`, `max_temp`, `avg_temp`, `daily_will_it_rain` - te i inne parametry określające pogodę dla danego dnia.

Hierarchia

- **Lokalizacja** — hierarchia oparta jest na lokalizacji geograficznej i zawiera następujące poziomy:
 - Kraj
 - Region
 - Miasto

Hierarchia zdefiniowana w powyższy sposób jest bardzo pomocna przy przeprowadzaniu analiz obejmujących wiele krajów, gdzie każdy z nich może być podzielony na wiele regionów i miast. Ułatwia ona wykonywanie analiz na różnych poziomach, krajowym lub regionalnym.

6. Warstwa raportowa

Tekst w tym rozdziale wygenerowano przy użyciu Claude - zwalidowała Natalia Choszczyk.

6.1. Dostęp do danych

Dane do warstwy raportowej Power BI zostały załadowane z bazy danych SQL Server w trybie importu. Cały schemat bazy danych wraz z tabelami i relacjami został zaimportowany do modelu Power BI. Tryb importu został wybrany ze względu na duży rozmiar danych.

6.2. Model biznesowy danych

Warstwa raportowa wykorzystuje wcześniej opisany schemat gwiazdy, który został bezpośrednio odwzorowany w Power BI. Model zachowuje wszystkie relacje między tabelami faktów i wymiarów, zapewniając spójność danych i efektywność zapytań analitycznych.

6.3. Hierarchie

W warstwie raportowej zostały zaimplementowane dwie główne hierarchie ułatwiające nawigację i analizę danych:

- **Hierarchia geograficzna:** kraj → region → miasto
- **Hierarchia czasowa:** rok → kwartał → miesiąc → dzień

6.4. Transformacje w obrębie warstwy raportowej

W warstwie raportowej zostały przeprowadzone następujące transformacje:

Ujednolicenie walut

Wszystkie ceny z kolumny **price** w tabeli **Fact_Offers** oraz **Dim_Property** zostały przeliczone na wspólną walutę euro i zapisane w nowej kolumnie **price_EUR**, która jest wykorzystywana we wszystkich analizach cenowych.

Optymalizacja wydajności

W odpowiedzi na problemy z wydajnością Power BI przy pracy z dużymi zbiorami danych, została stworzona pomocnicza tabela zawierająca kolumnę **property_sk** z identyfikatorami nieruchomości dostępnymi w każdy dzień wybranego zakresu dat. Rozwiązanie to zastąpiło złożone filtry wielokryterialne, które powodowały błędy obliczeniowe w Power BI.

Metryki biznesowe

W warstwie raportowej zostały utworzone następujące metryki:

- **Liczba dostępnych miejsc** – zlicza dostępne nieruchomości w wybranym okresie
- **Średnia cena w EUR** – oblicza średnią cenę dla dostępnych nieruchomości w euro
- **OfferScore** – metryka jakości oferty obliczana jako iloraz oceny przez cenę, służąca do rankingu ofert

6.5. Funkcjonalności raportowe

Raport został zaprojektowany z uwzględnieniem standardowego procesu decyzyjnego użytkownika, umożliwiając najpierw wybór miasta, a następnie analizę porównawczą między miastami. Zastosowano zaawansowane wizualizacje, w tym niestandardowe wykresy skrzypcowe wraz z wykresami skrzynkowymi pobrane z AppSource.

W celu zapewnienia wysokiej interaktywności i personalizacji analiz, zaimplementowano spójny system filtrów działający na wszystkich stronach raportu. Dodatkowo przeprowadzono analizy korelacji, takie jak zależność między różnymi czynnikami wpływającymi na ogólną ocenę obiektów, takimi jak ocena lokalizacji czy czystości.

7. Raporty dla użytkowników

Raporty zostały opracowane z wykorzystaniem programu **Power BI** i zostały udostępnione w formacie PDF. Są one również dostępne w wersji interaktywnej

Celem raportów jest wsparcie procesu decyzyjnego użytkowników portalu Airbnb przy wyborze miejsca na podróż. Analiza jest wykonywana dla określonego przedziału czasowego. Rekordy są filtrowane, aby zawierały tylko miejsca i oferty, które są dostępne w każdym z wybranych dni. W przedstawionym przykładzie analizie poddano tygodniowy okres od 30 czerwca do 6 lipca 2025 roku.

Struktura raportu obejmuje dwie sekcje. Pierwsza dotyczy analizy porównawczej kilku miast, a druga skupia się na danych z jednego wybranego miasta.

Sekcja pierwsza ma za zadanie pomóc użytkownikowi podjąć decyzję w jakim mieście wynająć nocleg. Jest to kompleksowe porównanie między różnymi miastami. W przykładowym raporcie porównujemy kilka stolic europejskich: Berlin, Lizbona, Londyn, Madryt, Paryż, Praga, Rzym oraz Wiedeń.

Dashboard umożliwia zdefiniowanie szczegółowych preferencji i filtrowanie wyników. Kryteria te obejmują: liczbę osób, wymaganą liczbę łóżek, typ nieruchomości, próg ocen dla ofert, zakres cenowy za dobę oraz kategorię pokoju. Wszystkie elementy wizualizacyjne raportu dynamicznie dostosowują się do wybranych parametrów.

Pierwsze cztery strony dokumentu koncentrują się na analizie porównawczej ośmiu europejskich stolic, podczas gdy kolejne trzy strony poświęcone są szczegółowej analizie wybranej destynacji.

7.1. Struktura raportu

Strona 1 - rysunek 7.1

- możliwość ustawienia personalizowanych filtrów
- mapa geograficzna z oznaczeniem liczby dostępnych ofert dla poszczególnych lokalizacji
- diagram treemap ilustrujący rozkład liczby ofert w analizowanych miastach
- macierz tabelaryczna prezentująca porównanie cen w zależności od miasta i kategorii pokoju z zaznaczeniem wyższych cen intensywniejszym kolorem

Strona 2 - rysunek 7.2

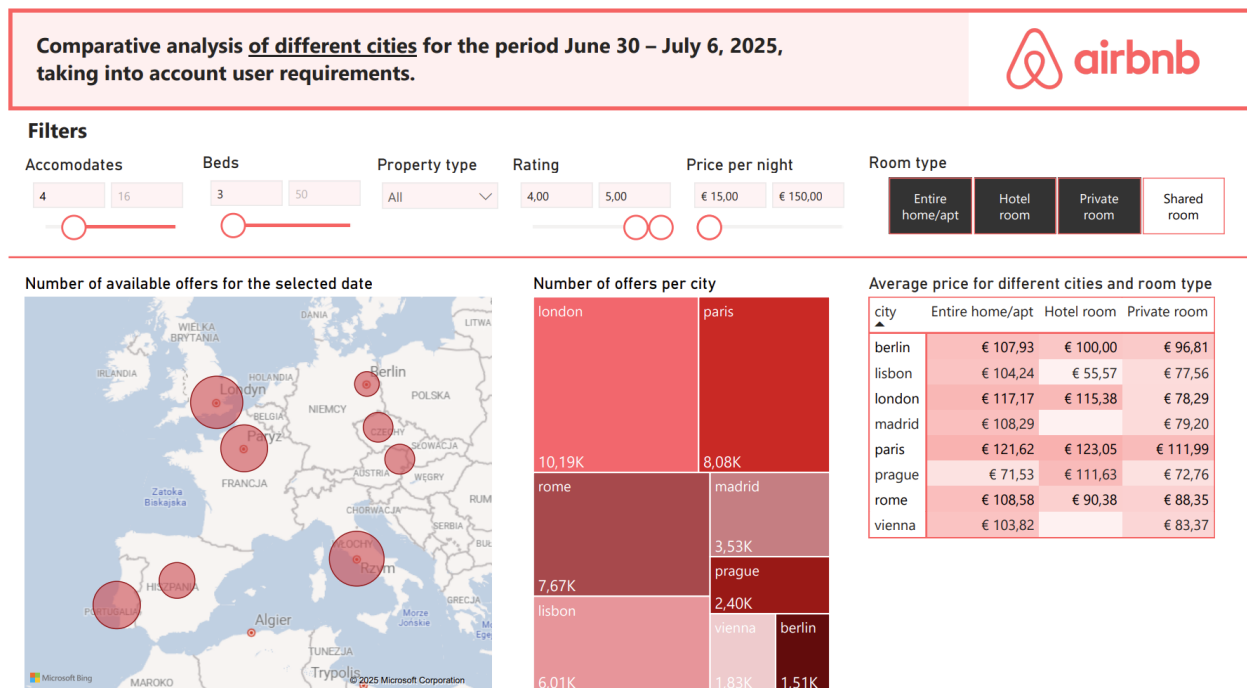
- tabela szczegółowa zawierająca kluczowe wskaźniki dla każdego miasta: liczbę dostępnych ofert, średnią cenę w euro, średnią liczbę opinii na ofertę, średnią ocenę ogólną, średnią ocenę czystości oraz średnią ocenę lokalizacji
- wykres liniowy porównujący wartości minimalne i maksymalne temperatury dla poszczególnych miast w analizowanym okresie
- wykres słupkowy pokazujący szansę na wystąpienie opadów w badanych lokalizacjach
- wykres punktowy obrazujący korelację między liczbą opinii a średnią oceną dla każdego miasta

Strona 3 - rysunek 7.3

- wykres wiolinowy przedstawiający rozkład cen w poszczególnych miastach

Strona 4 - rysunek 7.4

- wizualizacja kluczowych wskaźników obrazująca wpływ ocen czystości, lokalizacji i innych na ogólną ocenę



Rysunek 7.1: Raport - strona 1

Comparative analysis of different cities for the period June 30 – July 6, 2025, taking into account user requirements.




Detailed information by city

City	Number of properties	Average price in EUR	Variance of price in EUR	Average number of reviews	Average rating	Average cleanliness	Average location
vienna	896	€ 103,32	€ 889,41	61,31	4,73	4,72	4,70
berlin	587	€ 107,22	€ 930,94	92,01	4,75	4,72	4,74
london	2588	€ 113,73	€ 725,81	26,51	4,75	4,72	4,77
madrid	1592	€ 107,25	€ 748,38	80,09	4,71	4,73	4,78
paris	1015	€ 120,94	€ 651,97	43,23	4,78	4,73	4,85
lisbon	3230	€ 103,45	€ 888,45	83,27	4,74	4,75	4,74
prague	840	€ 71,78	€ 1 578,62	90,31	4,78	4,75	4,83
rome	3012	€ 107,51	€ 891,62	69,99	4,80	4,81	4,79

Weather by city

Average of min and max temperature by city




Average of daily chance of rain by city



Reviews by city

Average rating and average number of reviews by city




Rysunek 7.2: Raport - strona 2

Comparative analysis of different cities for the period June 30 – July 6, 2025, taking into account user requirements.



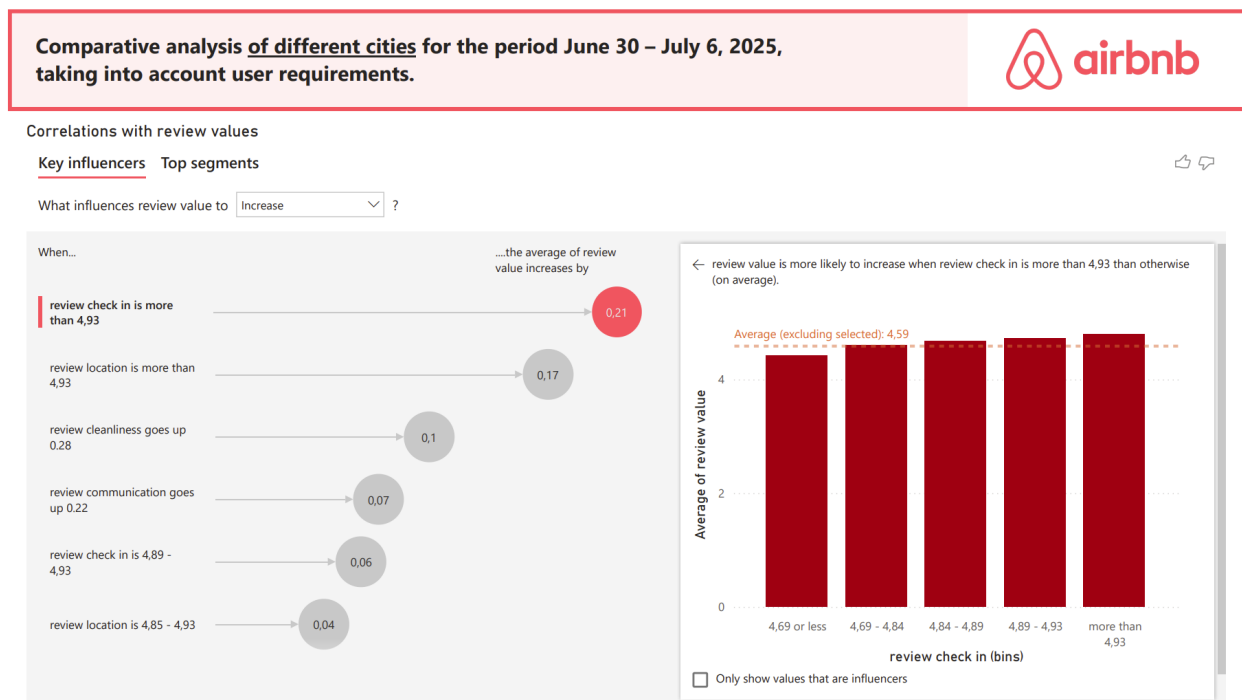
Average price by cities

▲ Average price ■ Median Value □ Mean Value



Rysunek 7.3: Raport - strona 3

7.1. STRUKTURA RAPORTU



Rysunek 7.4: Raport - strona 4

Strona 5 - rysunek 7.5

- możliwość wyboru spersonalizowanych filtrów
- lokalizacja dostępnych ofert na mapie interaktywnej
- liczba dostępnych ofert
- wykres kołowy ilustrujący strukturę procentową i liczebność poszczególnych kategorii pokoi
- seria wykresów wskaźnikowych przedstawiających: średnią ocenę ogólną, dokładność opisu, komunikację, czystość, zameldowanie i lokalizację


Strona 6 - rysunek 7.6

- możliwość wyboru spersonalizowanych filtrów
- rozkład cenowy przedstawiony na wykresie wiolinowym
- wartości mediany cen dla różnych kategorii pokoi
- wykres punktowy obrazujący zależność między ceną za dobę a oceną oferty
- średnia wartość minimalnej temperatury w analizowanym okresie

- średnia wartość maksymalnej temperatury w analizowanym okresie
- wykres liniowy dla najniższej i najwyższej temperatury w poszczególnych dniach

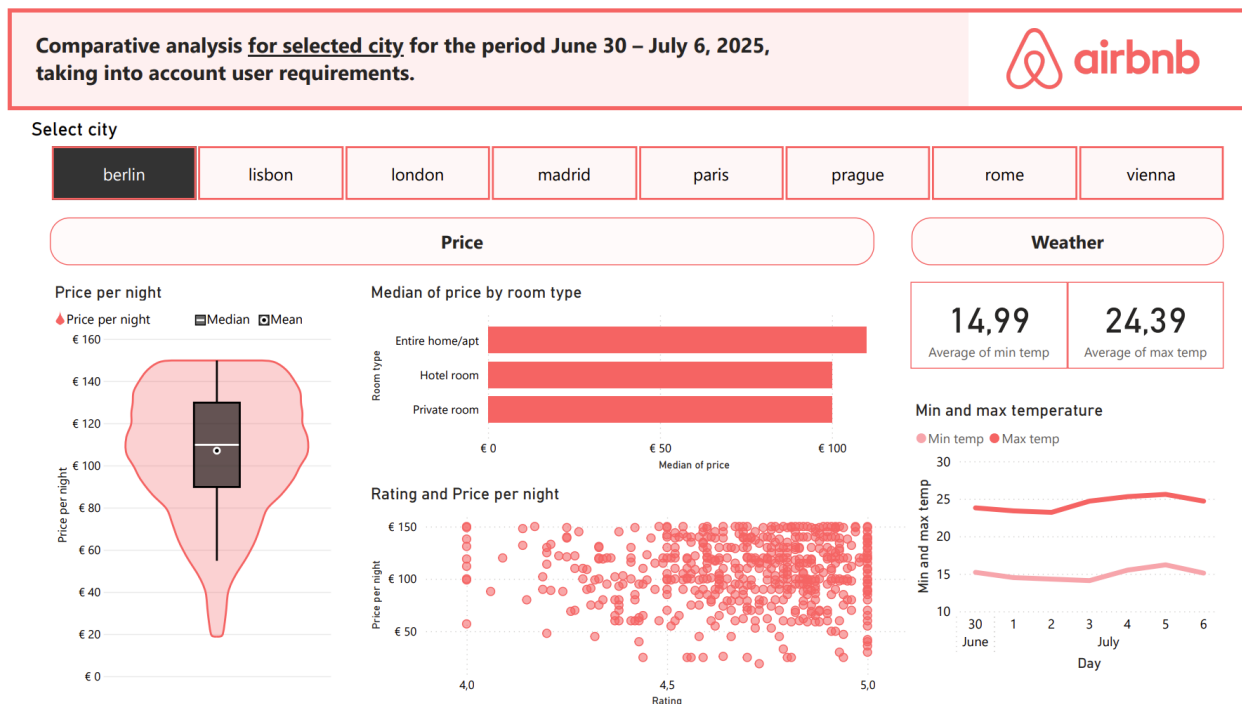
Strona 7 - rysunek 7.7

- możliwość wyboru spersonalizowanych filtrów
- tabela najlepszych ofert według ocen użytkowników pod względem ceny do jakości




Rysunek 7.5: Raport - strona 5

7.1. STRUKTURA RAPORTU




Rysunek 7.6: Raport - strona 6



Rysunek 7.7: Raport - strona 7

7.2. Interaktywność raportu

Raport jest interaktywny. Suwaki i inne przyciski na pierwszej stronie pozwalają na personalizację treści, a przyciski na stronach 5-7 pozwalają na wybór analizowanego miasta. Poniżej znajduje się fragment raportu wykonanego dla innego miasta niż we wcześniejszym przykładzie.



Rysunek 7.8: Fragment raportu dla Lizbony

8. Wykonane testy

8.1. Zasilanie pustej bazy danych

Cel:

Zasilenie hurtowni danych w celu analizy.

Sposób testowania:

Przeprowadzenie procesu ETL, gdy baza jest pusta.


Oczekiwany wynik:

Zasilenie bazy wszystkimi dostępnymi danymi, brak błędów.

Uzyskany wynik:

Zasilenie bazy wszystkimi dostępnymi danymi, brak błędów. Poprawność procesu ukazuje rysunek

8.1.



Rysunek 8.1: Proces ETL po zasileniu pustej bazy danych

8.2. Wykonywanie procesu ETL przy braku zmian w źródle danych

Cel:

Standardowe wykonanie całego procesu ETL. Rozważamy przypadek, gdy na stronie nie ma dostępnych nowych danych.

Sposób testowania:


Przeprowadzenie procesu ETL.

Oczekiwany wynik:

Brak błędów, brak zmian w bazie danych.

Uzyskany wynik:

Brak błędów, brak zmian w bazie danych. Poprawność procesu ukazują rysunki 8.2 - 8.3.




The screenshot shows a SQL query window with the following text:

```
SELECT distinct count(review_id) as Reviews_count_before  
FROM [AIRBNB_star_dwh].[dbo].[Fact_Review]
```

Below the query window, the 'Results' tab is active, displaying a single row of data:

	Reviews_count_before
1	758544

Rysunek 8.2: Widok przed ponownym wykonaniem procesu ETL



The screenshot shows a SQL query window with the following text:

```
SELECT distinct count(review_id) as Reviews_count_after  
FROM [AIRBNB_star_dwh].[dbo].[Fact_Review]
```

Below the query window, the 'Results' tab is active, displaying a single row of data:

	Reviews_count_after
1	758544

Rysunek 8.3: Widok po ponownym wykonaniu procesu ETL - bez braku zmian w bazie

8.3. Wykonywanie procesu ETL przy obecnych zmianach w źródle danych - nowe miasta

Cel:

Zweryfikowanie, czy system prawidłowo przetwarza dane, gdy na stronie pojawi się całkowicie nowy plik.

Sposób testowania:


Dodanie nowego miasta do listy analizowanych, co skutkuje uwzględnieniem dodatkowych plików. Na potrzeby testu rozważamy sytuację początkową, gdy w bazie są dane z Pragi, a pojawiają się nowe dane z Berlina.

Oczekiwany wynik:

Nowe pliki zostaną poprawnie wczytane i przetworzone przez ETL, a dane z nowych plików pojawią się w bazie danych i raporcie Power BI.

Uzyskany wynik:

Plik został poprawnie odczytany i przetworzony, a dane pojawiły się w bazie danych oraz raporcie. Poprawność procesu ukazują rysunki 8.4 - 8.5.



```
SELECT distinct count(review_id) as Reviews_count_before_for_Prague
FROM [AIRBNB_star_dwh].[dbo].[Fact_Review]
where city = 'prague'

SELECT distinct count(review_id) as Reviews_count_before_for_Berlin
FROM [AIRBNB_star_dwh].[dbo].[Fact_Review]
where city = 'berlin'

SELECT distinct(city)
FROM [AIRBNB_star_dwh].[dbo].[Fact_Review]
```

Reviews_count_before_for_Prague	
1	758544

Reviews_count_before_for_Berlin	
1	0

city	
1	prague

Rysunek 8.4: Widok przed dodaniem nowego pliku

```

SELECT distinct count(review_id) as Reviews_count_after_for_Prague
FROM [AIRBNB_star_dwh].[dbo].[Fact_Review]
where city = 'prague'

SELECT distinct count(review_id) as Reviews_count_after_for_Berlin
FROM [AIRBNB_star_dwh].[dbo].[Fact_Review]
where city = 'berlin'

SELECT distinct(city)
FROM [AIRBNB_star_dwh].[dbo].[Fact_Review]

```

Results	
Reviews_count_after_for_Prague	
1	758544
Reviews_count_after_for_Berlin	
1	588592
city	
1	berlin
2	prague

Rysunek 8.5: Widok po dodaniu nowego pliku

8.4. Dodanie nowej obserwacji

Cel:

Weryfikacja, czy dodanie nowej obserwacji w pliku źródłowym (dla przykładu w pliku `calendar`) jest przetwarzane w poprawny sposób i czy zostaje dodana poprawna obserwacja w kolejnych etapach przepływu.

Sposób testowania:

Nowy wiersz został dodany do pliku `calendar` dla miasta Praga. Następnie został uruchomiony proces ETL, a raport w Power BI został odświeżony.

Oczekiwany wynik:

Nowa obserwacja zostaje poprawnie załadowana do bazy.

Uzyskany wynik:

Rekord został poprawnie przetworzony przez proces ETL i załadowany do bazy danych. Potwierdzają to rysunki 8.6 - 8.8.

8.4. DODANIE NOWEJ OBSERWACJI

20250316_czech-republic-prague-prague_calendar.csv — Notatnik

Plik Edycja Format Widok Pomoc

```
780866,2026-03-02,f,$26.00,2,60
780866,2026-03-03,f,$26.00,2,60
780866,2026-03-04,f,$26.00,2,60
780866,2026-03-05,f,$26.00,2,60
780866,2026-03-06,f,$26.00,2,60
780866,2026-03-07,f,$26.00,2,60
780866,2026-03-08,f,$26.00,2,60
780866,2026-03-09,f,$26.00,2,60
780866,2026-03-10,f,$26.00,2,60
780866,2026-03-11,f,$26.00,2,60
780866,2026-03-12,f,$26.00,2,60
780866,2026-03-13,f,$26.00,2,60
780866,2026-03-14,f,$26.00,2,60
780866,2026-03-15,f,$26.00,2,60
23163,2026-03-16,t,$25.00,2,60
```

Rysunek 8.6: Dodanie nowej obserwacji manualnie do pliku calendar dla miasta Praga

```
SELECT TOP (1000) [offer_id]
,[property_id],[offer_date],[available],[price],
[weather_id],[scrape_date],[country],[region],[city]
FROM [AIRBNB_star_dwh].[dbo].[Fact_Offers]
WHERE property_id = 302561
ORDER BY offer_id desc
```

	offer_id	property_id	offer_date	available	price	weather_id	scrape_date	country	region	city
1	31469990	302561	2026-03-15	NO	156.00	prague20260315	20250316	czech-republic	prague	prague
2	31469989	302561	2026-03-14	NO	156.00	prague20260314	20250316	czech-republic	prague	prague
3	31469988	302561	2026-03-13	NO	156.00	prague20260313	20250316	czech-republic	prague	prague
4	31469987	302561	2026-03-12	NO	156.00	prague20260312	20250316	czech-republic	prague	prague
5	31469986	302561	2026-03-11	NO	156.00	prague20260311	20250316	czech-republic	prague	prague
6	31469985	302561	2026-03-10	NO	156.00	prague20260310	20250316	czech-republic	prague	prague
7	31469984	302561	2026-03-09	NO	156.00	prague20260309	20250316	czech-republic	prague	prague
8	31469983	302561	2026-03-08	NO	156.00	prague20260308	20250316	czech-republic	prague	prague
9	31469982	302561	2026-03-07	NO	156.00	prague20260307	20250316	czech-republic	prague	prague
10	31469981	302561	2026-03-06	NO	156.00	prague20260306	20250316	czech-republic	prague	prague

Rysunek 8.7: Widok ofert dla miasta Praga i tej nieruchomości przed dodaniem nowej obserwacji posortowany po offer_id - widoczny brak oferty, którą chcemy dodać

```
SELECT TOP (1000) [offer_id]
,[property_id],[offer_date],[available],[price],
[weather_id],[scrape_date],[country],[region],[city]
FROM [AIRBNB_star_dwh].[dbo].[Fact_Offers]
WHERE property_id = 302561
ORDER BY offer_id desc
```

	offer_id	property_id	offer_date	available	price	weather_id	scrape_date	country	region	city
1	40244526	302561	2026-03-16	YES	25.00	prague20260316	20250316	czech-republic	prague	prague
2	31469990	302561	2026-03-15	NO	156.00	prague20260315	20250316	czech-republic	prague	prague
3	31469989	302561	2026-03-14	NO	156.00	prague20260314	20250316	czech-republic	prague	prague
4	31469988	302561	2026-03-13	NO	156.00	prague20260313	20250316	czech-republic	prague	prague
5	31469987	302561	2026-03-12	NO	156.00	prague20260312	20250316	czech-republic	prague	prague
6	31469986	302561	2026-03-11	NO	156.00	prague20260311	20250316	czech-republic	prague	prague
7	31469985	302561	2026-03-10	NO	156.00	prague20260310	20250316	czech-republic	prague	prague
8	31469984	302561	2026-03-09	NO	156.00	prague20260309	20250316	czech-republic	prague	prague
9	31469983	302561	2026-03-08	NO	156.00	prague20260308	20250316	czech-republic	prague	prague
10	31469982	302561	2026-03-07	NO	156.00	prague20260307	20250316	czech-republic	prague	prague
11	31469981	302561	2026-03-06	NO	156.00	prague20260306	20250316	czech-republic	prague	prague
12	31469980	302561	2026-03-05	NO	156.00	prague20260305	20250316	czech-republic	prague	prague
13	31469979	302561	2026-03-04	NO	156.00	prague20260304	20250316	czech-republic	prague	prague
14	31469978	302561	2026-03-03	NO	156.00	prague20260303	20250316	czech-republic	prague	prague
15	31469977	302561	2026-03-02	NO	156.00	prague20260302	20250316	czech-republic	prague	prague
16	31469976	302561	2026-03-01	NO	156.00	prague20260301	20250316	czech-republic	prague	prague

Rysunek 8.8: Widok po dodaniu nowej obserwacji - widać, że obserwacja pojawiła się poprawnie w tabeli

8.5. Aktualizacja obserwacji w Dim_Property - test działania SCD2

Cel:

Sprawdzenie poprawności działania metody SCD2 w tabeli Dim_Property, który polega na zapisywaniu historii zmian w danych.

Sposób testowania:

Zmieniono manualnie wartość jednego z atrybutów w jednym rekordzie źródłowym. Następnie uruchomiono proces ETL w celu wprowadzenia zmian.

Oczekiwany wynik:

Nowy rekord z zaktualizowaną wartością dodany do tabeli Dim_Property z nowym kluczem zastępczym, a poprzedni rekord oznaczony jako nieaktywny.

Uzyskany wynik:

Mechanizm SCD2 zadziałał poprawnie. Zmodyfikowany rekord został dodany do bazy i przypisany został do niego nowy klucz zastępczy. Poprzednia wersja została oznaczona jako nieaktywna - wartość w kolumnie isActive zmieniono na NO. Poprawność procesu ukazują rysunki 8.9 - 8.12.

```
1020234,2025-03-16,HOME SWEET HOME in heart of Prague,227945,Alex And Kate,2010-09-08,within an hour,100%,100%,f,123.0,194.0,t,50.08478,14.42096,Entire rental unit,Entire home/apt,4,1.0,1.0,2.0,"$1,876.00",2,365,t,14,42,51,51,572,65,5,4.53,4.64,4.59,4.63,4.76,4.91,4.6,t,101,101,0,0,3.93
```

Rysunek 8.9: Oryginalny rekord w pliku źródłowym przed zmianą wartości

```
1020234,2025-03-16,HOME SWEET HOME in heart of Prague,227945,Alex And Kate,2010-09-08,within an hour,100%,100%,f,123.0,194.0,t,50.08478,14.42096,Entire rental unit,Entire home/apt,4,2.0,1.0,2.0,"$1,876.00",2,365,t,14,42,51,51,572,65,5,4.53,4.64,4.59,4.63,4.76,4.91,4.6,t,101,101,0,0,3.93
```


Rysunek 8.10: Rekord w pliku źródłowym po zmianie wartości w kolumnie bathrooms z 1 na 2

```
SELECT TOP (1000) [property_sk],[property_id],[property_name],[host_name],[accommodates],[bathrooms],[bedrooms],[beds],[isActive],[vaildFrom],[validTo]
FROM [AIRBNB_star_dwh].[dbo].[Dim_Property]
WHERE property_id = 1020234
```

	property_sk	property_id	property_name	host_name	accommodates	bathrooms	bedrooms	beds	isActive	vaildFrom	validTo
1	302625	1020234	HOME SWEET HOME in heart of Prague	Alex And Kate	4	1	1	2	YES	20250611	99991231

Rysunek 8.11: Widok wszystkich nieruchomości o id równym 1020234 obecnych w tabeli przed aktualizacją w Dim_Property

8.6. BRAK POŁĄCZENIA Z WEATHERAPI - TRAFIENIE W CZAS NIEDOSTĘPNOŚCI



	property_sk	property_id	property_name	host_name	accommodates	bathrooms	bedrooms	beds	isActive	vaildFrom	validTo
1	302625	1020234	HOME SWEET HOME in heart of Prague	Alex And Kate	4	1	1	2	NO	20250611	20250611
2	326614	1020234	HOME SWEET HOME in heart of Prague	Alex And Kate	4	2	1	2	YES	20250611	99991231

Rysunek 8.12: Widok wszystkich nieruchomości o id równym 1020234 obecnych w tabeli po aktualizacji - widoczny nowy rekord oraz stary rekord oznaczony jako nieaktywny

8.6. Brak połączenia z WeatherAPI - trafienie w czas niedostępności

Cel:

Odporność na czas nieaktywności API portalu WeatherAPI.

Sposób testowania:

Przeprowadzenie procesu pobierania danych pogodowych.

Oczekiwany wynik:

Poprawnie załadowane dane, mimo chwilowego braku aktywności serwera API.

Uzyskany wynik:

Dane zostały poprawnie załadowane, dzięki ponownym próbom łączenia po odczekaniu określonego czasu. Szczegóły ukazuje rysunek 8.13.

```
ⓧ Zapisano dane pogodowe dla miasta madrid - 365/365 dni.
⚠ Błąd API przy rome (20250909): (502)
Reason: Bad Gateway
HTTP response headers: HTTPHeaderDict({'Date': 'Tue, 10 Jun 2025 22:08:29 GMT', 'Content-Type': 'text/html', 'Transfer-Encoding': 'chunked', 'Connection': 'keep-alive', 'Server': 'BunnyCDN-DE1-1048', 'CDN-PullZone': '93447', 'CDN-Uid': '8fa3a04a-75d9-4707-8056-b7b33cac7fe', 'CDN-RequestCountryCode': 'PL', 'Cache-Control': 'no-cache', 'ErrorCode': '105', 'CDN-RequestId': '58ba33acd70569d447594bab41066acd', 'CDN-Cache': 'EXPIRED', 'CDN-Status': '502', 'CDN-RequestTime': '0'})
HTTP response body: <!DOCTYPE html>
<html>
<head>
<title>502 Bad Gateway</title>
<meta name="viewport" content="width=device-width, initial-scale=1" />
<link rel="icon" type="image/png" sizes="16x16" href="https://bunnynetassets.b-cdn.net/error.png" />
<script src="https://bunny.net/lib/jquery/jquery.min.js"></script>
<script src="https://cdn.statuspage.io/se-v2.js"></script>
<link rel="stylesheet" href="https://bunnynetassets.b-cdn.net/error.css">
</head>
<body>
<div class="hero"><div class="content"><div class="alert-details"><h3 class="alert">ERROR 502</h3><h1>Bad Gateway</h1><h3>We could not establish a connection to api.weatherapi.com</h3></div><div class="row cards"><div class="col-md g-md-1"><div class="card"> <h2>You</h2> <small>IP: 194.29.131.208</small></div></div><div class="col-md-1 g-md-1 icons"> </div><div class="col-md g-1"><div class="card"> <h2>bunny.net</h2> <small>Edge Network</small></div><div class="col-md-1 g-md-1 icons"> </div><div class="col-md g-1"><div class="card"> <h2>api.weatherapi.com</h2> <small>Your Destination</small></div></div></div><div class="final-details"><div class="box"><h1>What happened?</h1><div class="description">There was a problem that occurred while connecting to api.weatherapi.com origin server. The server hosting the website might be unavailable.</div></div><div class="box"><h1>What can I do?</h1><div class="description">If you are a visitor, please try again in a few minutes. If you are the administrator, please check your origin server status.</div></div></div>
</body>
</html>
ⓧ Zapisano dane pogodowe dla miasta rome - 365/365 dni.
```

Rysunek 8.13: Przypadek braku dostępności serwera API portalu WeatherAPI - pierwsza próba zakończyła się błędem. Widzimy w dolnej sekcji, że udało się pobrać wszystkie potrzebne dane

8.7. Ładowanie danych do narzędzia BI

Cel:

Odświeżenie danych w systemie Power BI oraz aktualizacja wykresów.

Sposób testowania:

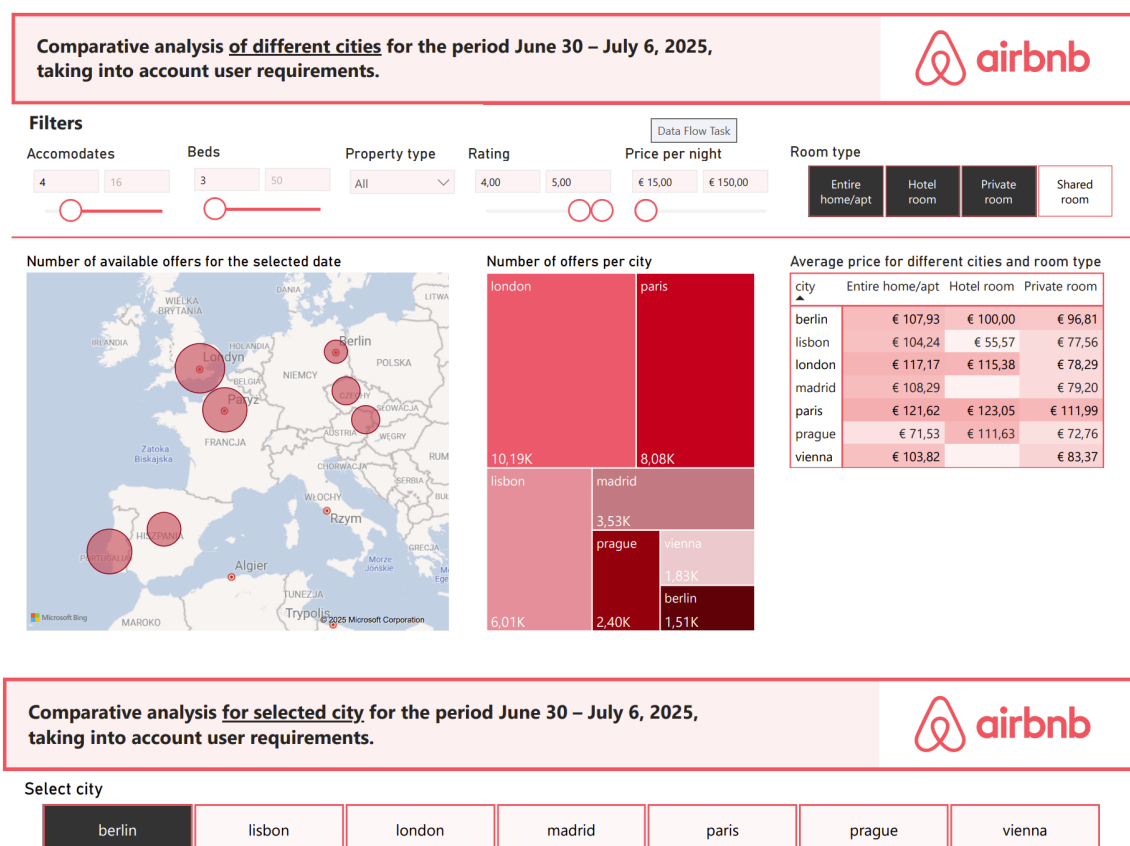
Do bazy zostały dodane dane jednego miasta - Rzymu. Następnie należało odświeżyć dane w systemie Power BI i obserwować zmianę w wizualizacjach.

Oczekiwany wynik:


Zaktualizowane wizualizacje, poszerzone o nowe miasto.

Uzyskany wynik:

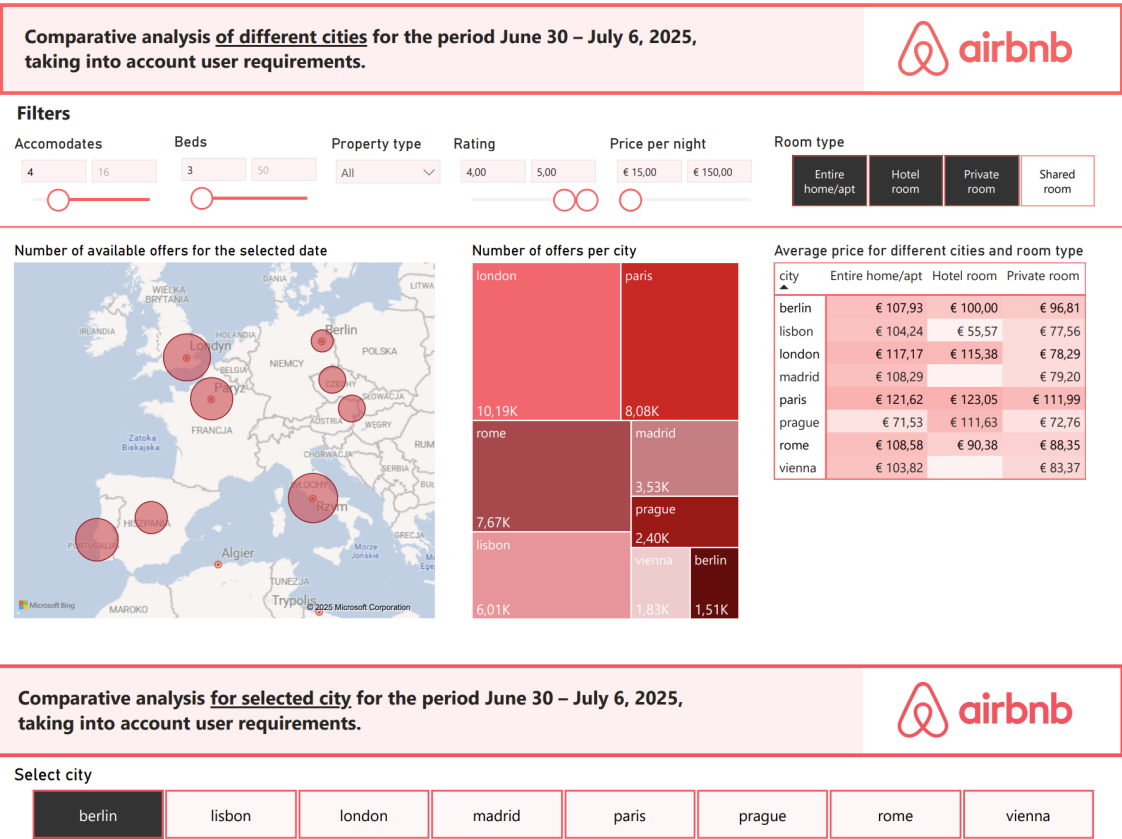
Raport został skutecznie zaktualizowany o dodatkowe miasto. Dane zostały ponownie pobrane z bazy. Poprawność procesu ukazują rysunki 8.14 - 8.16.



Rysunek 8.14: Fragment raportu przed dodaniem miasta



Rysunek 8.15: Odświeżanie danych w systemie Power BI



Rysunek 8.16: Fragment raportu po dodaniu miasta

8.8. End-to-end test

Cel:

Sprawdzenie poprawności całego procesu przepływu oraz wizualizacji danych - od źródła danych, przez proces ETL, załadowanie danych do bazy, aż po wizualizację w raporcie Power BI i finalny dashboard.

Sposób testowania:


Uruchomienie po kolei wszystkich elementów procesu.

Oczekiwany wynik:

Poprawnie wykonany cały proces bez błędów na każdym z jego etapów. Finalny dashboard.

Uzyskany wynik:

Dane zostały poprawnie pobrane i załadowane. Proces ETL przebiegł bezbłędnie. Dane zostały poprawnie załadowane do bazy i zwizualizowane w systemie Power BI. Poprawność procesu ukazują rysunki 8.17 - 8.20.



Rysunek 8.17: Wykonanie procesu ETL

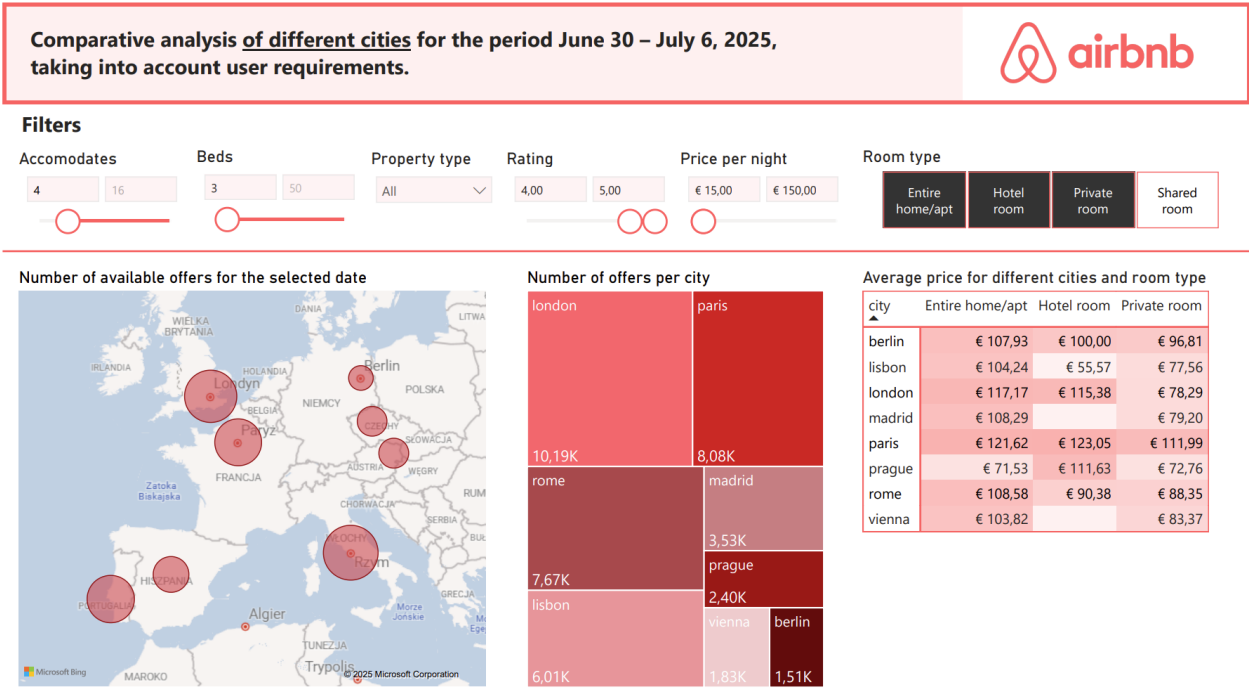
	property_id	last_scraped	property_name	host_id	host_name	host_since	host_response_time	host_response_rate	host_acceptance_rate
1	2737	2025-03-05	Elif's room in cozy, clean flat.	3047	Elif	2008-09-18	within a few hours	100	0
2	3079	2025-03-08	Cozy apartment (2-4)with Colisseum view	3504	Laura	2008-10-08	within a day	100	0
3	3109	2025-03-11	zen and calm	3631	Anne	2008-10-14	within a few hours	100	100
4	3176	2025-03-16	Fabulous Flat in great Location	3718	Britta	2008-10-19	within a day	67	40
5	5396	2025-03-03	Your perfect Paris studio on Île Saint-Louis	7903	Borzou	2009-02-14	within an hour	100	92

Rysunek 8.18: Dane załadowane do bazy

8.8. END-TO-END TEST

property_id	last_scraped	property_name	host_id	host_name	host_since
380239	wtorek, 4 marca 2025	Bienvenue aux Batignolles!	1908045	Melanie	poniedziałek, 12 marca
556557	wtorek, 4 marca 2025	location du musicien	2736768	Octavio	poniedziałek, 25 czerwca
1017342	wtorek, 4 marca 2025	Appartement Bastille / Le Marais	5599245	Ghislain	niedziela, 24 marca
1267022	wtorek, 4 marca 2025	DESIGN APT view on Sacred Heard !	6832090	Emmanuelle	poniedziałek, 10 czerwca
1372126	wtorek, 4 marca 2025	Studio 30m2 down town Paris	7438470	Marine	piątek, 12 lipca
1455666	wtorek, 4 marca 2025	Typical French flat - Bastille 50m2	5547857	Doriane	środa, 20 marca
1795899	wtorek, 4 marca 2025	Charming apartment in Montorgueil	4556109	Constance	środa, 2 stycznia
1852572	wtorek, 4 marca 2025	Charmant 2p vue sur montmartre	4270621	Aline	środa, 28 listopada

Rysunek 8.19: Dane załadowane do Power BI



Rysunek 8.20: Gotowe wizualizacje w Power BI

9. Podsumowanie rezultatów projektu

Projekt stworzenia hurtowni danych oraz warstwy analitycznej z wykorzystaniem danych dotyczących wynajmów na platformie Airbnb oraz zewnętrznych danych pogodowych dostarcza kompleksowe rozwiązanie analityczne.

Proces ETL skutecznie obsługuje ogromne zbiory danych, ale również umożliwia wykonanie analiz dla wybranych lokalizacji, na przykład dla kilku europejskich stolic. Proces charakteryzuje się wysoką wydajnością oraz elastycznością i skalowalnością. Kluczowym osiągnięciem było połączenie dwóch źródeł danych - Airbnb oraz WeatherAPI. Pozwoliło to na znaczne rozszerzenie analizy. Hurtownia danych w schemacie gwiazdy zapewniła optymalne i wygodne tworzenie analiz wykorzystujących dane z wielu tabel. Jest to optymalna struktura analityczna.

Dwuetapowe raportowanie - porównanie miast, a później analiza wybranego miasta - odpowiada temu, jak użytkownicy realnie planują podróże. Wskazuje to na wysoką funkcjonalność i odniesienie do realiów. Dynamiczne i przejrzyste filtry pozwalają na wysoką personalizację rekomendacji. Przedstawione zależności dotyczące opinii, cen oraz pogody dostarczają użytecznych informacji nie tylko dla użytkowników portalu, ale również dla właścicieli nieruchomości.

System cechuje się wysokim potencjałem komercyjnym. Umożliwia różnorodną rozbudowę każdego z elementów - od załadowania odpowiednich danych, przez ich transformację po warstwę analityczną. Z łatwością można dołączyć nowe regiony, źródła danych lub inny rodzaj analiz. Różnorodność danych oraz mnogość informacji dostępnych dla każdej oferty, czy nieruchomości pozwala na wykonanie bardzo różnorodnych analiz.

Analiza może być wykorzystywana przez użytkowników platformy Airbnb chcących zarezerwować nocleg, przez właścicieli nieruchomości, czy organizacje turystyczne w celu optymalizacji strategii biznesowych. Projekt zapewnia bardzo praktyczne narzędzie decyzyjne i analityczne w dynamicznym środowisku rynku turystycznego.

10. Podział pracy w zespole

Zadanie	Osoba odpowiedzialna
Research zbiorów danych i tematu projektu	Natalia Choszczyk, Filip Langiewicz
Model hurtowni	Natalia Choszczyk, Filip Langiewicz
Proces ETL	Filip Langiewicz
Raporty	Natalia Choszczyk
Testy	Filip Langiewicz
Dokumentacja	Natalia Choszczyk, Filip Langiewicz

Tabela 10.1: Podział zadań