

Hurtownie danych i systemy Business Intelligence

Analiza danych z platformy Airbnb
w hurtowni danych z wykorzystaniem
danych zewnętrznych

Natalia Choszczyk | Filip Langiewicz

nr indeksu 327267 | nr indeksu 327293

Politechnika Warszawska

Wydział Matematyki i Nauk Informatycznych

21 maja 2025

Spis treści

1. Temat i cel projektu	3
2. Diagram oraz opis proponowanej architektury rozwiązania procesu ETL .	4
2.1. Sposoby transformacji i integracji danych	6
2.1.1. Transformacja danych	6
2.1.2. Integracja danych	7
2.1.3. Podsumowanie	7
3. Wykorzystywane zbiory danych	8
3.1. Platforma Airbnb	8
3.2. Prognoza pogody	8
4. Model fizyczny hurtowni danych	9
4.1. Tabele faktów	10
4.2. Tabele wymiarów	10
5. Kluczowe miary i atrybuty w modelu	15
6. Planowane raporty dla użytkowników	17
7. Planowane testy	18

1. Temat i cel projektu


Analiza danych z platformy Airbnb w hurtowni danych z wykorzystaniem danych zewnętrznych, takich jak pogoda, czy lokalizacja.

Celem projektu jest analiza wpływu czynników zewnętrznych na to, w jaki sposób ludzie rezerwują noclegi na platformie Airbnb. Te czynniki to między innymi prognozowane warunki pogodowe, opinie i oceny użytkowników, czy dostępność opcji noclegowych w danym rejonie. Celem projektu jest zrozumienie, w jaki sposób te zmienne, ale też na przykład pory roku i sezony np. wakacyjne/zimowe wpływają na cenę wynajmu, ale też dostępność i preferencje użytkowników.

Projekt umożliwi użytkownikom platformy Airbnb na lepsze i bardziej świadome planowanie podróży, w oparciu o realne dane, co może w przyszłości pozytywnie wpłynąć na oszczędność pieniędzy oraz ogólną satysfakcję użytkownika. Rozwiązanie umożliwi znalezienie najbardziej opłacalnych terminów wyjazdów, a oznacza to najlepszą pogodę i najniższe ceny przy dobrych warunkach noclegowych. Zbadane zostaną również interakcje między poszczególnymi czynnikami, co pozwoli na zaobserwowanie ukrytych zależności w danych

2. Diagram oraz opis proponowanej architektury rozwiązania procesu ETL

Poniższy diagram (rysunek 2.1) przedstawia ogólną architekturę zaprojektowanego procesu ETL, którego celem jest pobieranie, przetwarzanie i ładowanie danych z platformy Airbnb oraz z API pogodowego do hurtowni danych. Proces ten został zorganizowany w logiczne kroki, które umożliwiają modularne przetwarzanie poszczególnych aspektów danych: ofert (listings), recenzji (reviews), kalendarza dostępności (calendar).



Rysunek 2.1: Model procesu ETL

Wygenerowano przy użyciu ChatGPT - zwalidował Filip Langiewicz.

Opis ogólny

Proces ETL rozpoczyna się od zadania głównego **Airbnb ETL**, które koordynuje pobieranie i dalsze przetwarzanie danych. W ramach tego procesu realizowane są następujące kroki:

- **Fetch Airbnb Data** – inicjalne pobranie danych ze źródła (plików). Pliki z nowych miejsc, które jeszcze nigdy nie były w bazie trafiają do folderu NEW. Jeżeli dla danego miasta

istnieje wersja bardziej aktualna, to trafia do folderu UPDATE. Dane, które aktualnie są w hurtowni przechowywane są w folderze DB.

- **Foreach Loop Remove Updates** – przetwarzanie aktualizacji, gdzie starsze rekordy są identyfikowane i usuwane z bazy danych (**Remove Old Records**), po wykonaniu odpowiedniego skryptu.
- **Remove from DB** – krok usuwający stare pliki z folderu DB (gdzie są przechowywane najbardziej aktualne dane w hurtowni) w celu zastąpienia ich nowszymi wersjami w dalszej kolejności.
- **Move Updates** – dane są przenoszone do odpowiednich lokalizacji w systemie (z folderu UPDATE do NEW), w celu dalszego przetwarzania. Następnie przetwarzane są tylko pliki z folderu NEW (czyli nowsze wersje albo nowe miejsca).
- **Foreach Loop Listings** – iteracyjne przetwarzanie danych dotyczących ofert. W ramach tej pętli wykonywany jest skrypt przygotowujący dane, a następnie ładowane są one do odpowiednich struktur bazodanowych poprzez komponent **DFT_Load_Listings**. W czasie procesowania danych w tym komponencie następuje przetwarzanie i dodawanie odpowiednich kolumn.
- **Foreach Loop Reviews** – analogicznie do ofert, dane dotyczące recenzji są przetwarzane i ładowane do bazy danych (**DFT_Load_Reviews**).
- **Foreach Loop Calendar** – pętla odpowiedzialna za przetwarzanie informacji o dostępności nieruchomości. Dane są przetwarzane i ładowane do struktury kalendarza (**DFT_Load_Calendar**).
- **Move Updates** – dane są przenoszone do odpowiednich lokalizacji w systemie (z folderu NEW do DB).
- **GET Weather** – integracja z serwisem pogodowym w celu wzbogacenia danych kalendarza o informacje pogodowe, co może mieć wpływ na dostępność i atrakcyjność ofert.

Cały proces charakteryzuje się modularnością, możliwością łatwej rozbudowy oraz przejrzystością działania. Dzięki zastosowaniu pętli typu **Foreach Loop**, możliwe jest iteracyjne przetwarzanie dużych zbiorów danych w sposób zautomatyzowany i powtarzalny.

2.1. Sposoby transformacji i integracji danych

Proces ETL zaprojektowany dla projektu integracji danych z platformy **Airbnb** obejmuje szereg operacji transformacyjnych i integracyjnych, których celem jest przygotowanie danych źródłowych do dalszej analizy w hurtowni danych **AIRBNB_star_dwh** (Microsoft SQL Server). Transformacje mają zapewnić wysoką jakość, spójność i jednolitą strukturę danych, natomiast integracja – wydajny dostęp do informacji w modelu gwiazdy.

2.1.1. Transformacja danych

Transformacje realizowane są głównie w obrębie pętli **Foreach Loop** odpowiadających poszczególnym domenom danych (*listings*, *reviews*, *calendar*).

1. Uzupełnianie braków danych

Wartości NULL są zamieniane na:

- YES/NO – dla pól logicznych (np. `host_is_superhost`),
- 0 – dla pól liczbowych,
- pusty łańcuch znaków – dla pól tekstowych.

2. Standaryzacja formatów

- Pola logiczne `t/f` → YES/NO.
- Pola walutowe (np. `price`) – usunięcie symbolu waluty, zamiana przecinka na kropkę i konwersja do `FLOAT`.
- Konwersja wszystkich łańcuchów do kodowania `Unicode` (`UTF-8`).

3. Ujednolicenie długości ciągów znaków

Wartości tekstowe są mapowane do długości zdefiniowanej w schemacie (np. `NVARCHAR(255)`).

4. Dodanie kolumn technicznych

Każdy rekord otrzymuje metadane:

<code>scrape_date</code>	data scrapowania pliku,
<code>country</code>	kraj,
<code>region</code>	region administracyjny,
<code>city</code>	miasto.

2.1. SPOSOBY TRANSFORMACJI I INTEGRACJI DANYCH

Dzięki temu możliwa jest analiza historyczna i segmentacja geograficzna.

2.1.2. Integracja danych

1. Kolejność ładowania

Najpierw ładowane są wymiary (ang. *dimensions*), a następnie fakty (ang. *facts*), co minimalizuje ryzyko naruszenia kluczy obcych.

2.1.3. Podsumowanie

Zaprojektowane transformacje gwarantują spójność typów danych, eliminację błędów oraz wprowadzenie jednolitych standardów zapisu. Efektem integracji jest hurtownia oparta na schemacie gwiazdy, umożliwiającą szybkie i elastyczne raportowanie informacji o ofertach, recenzjach, cenach i dostępności w różnych przekrojach czasowych i geograficznych.

3. Wykorzystywane zbiory danych

3.1. Platforma Airbnb

Dane z platformy Airbnb dostępne są na stronie <https://insideairbnb.com/>. Dane są podzielone na regiony. Dla każdego regionu korzystamy z trzech plików `.csv`:


- `calendar.csv.gz` - opisuje ceny i dostępność danego miejsca w poszczególnych dniach,
- `listings.csv.gz` - dotyczy ofert noclegów,
- `reviews.csv.gz` - zawiera opinie wystawione dla poszczególnych obiektów.

Dane pochodzą z okresu jednego roku w przód, dotyczą ofert w przyszłości, czyli tych, które widzimy w serwisie Airbnb na najbliższy rok. Dane są aktualizowane nieregularnie - różnie dla poszczególnych regionów, jednak średnio nowe dane otrzymujemy co 3 miesiące. Dostęp do danych uzyskujemy poprzez scrapowanie strony skryptem pythonowym, który pobiera i zapisuje te dane.

3.2. Prognoza pogody

Dane pogodowe uzyskujemy ze strony <https://www.weatherapi.com/>. Pozyskujemy w ten sposób prognozę pogody na 300 dni do przodu. Dane są dostępne dla konkretnej lokalizacji na podstawie współrzędnych geograficznych lub nazwy miasta. Prognoza jest regularnie aktualizowana - co 4-6 godzin. Dostęp do API strony uzyskujemy po zalogowaniu się na stronę i wygenerowaniu klucza dostępu API. Dane pobieramy z API skryptem Pythonowym i następnie są one ładowane do bazy danych.

4. Model fizyczny hurtowni danych



Rysunek 4.1: Model hurtowni danych oparty na danych z Airbnb

Powyższy rysunek 4.1 przedstawia model hurtowni danych bazujący na schemacie gwiazdy. Model składa się z dwóch tabel faktów oraz trzech tabel wymiarów.

4.1. Tabele faktów

- **Fact_Offers** – zawiera informacje dotyczące ofert wynajmu na dany dzień, takie jak cena, dostępność, liczba minimalnych i maksymalnych nocy, czy lokalizacja. Połączona z tabelami wymiarów: *Dim_Property*, *Dim_Weather*, *Dim_Date*.
- **Fact_Review** – zawiera dane dotyczące recenzji wystawionych przez użytkowników, w tym datę wystawienia, dane wystawiającego oraz odniesienie do obiektu. Połączona z: *Dim_Property*, *Dim_Date*.

4.2. Tabele wymiarów

- **Dim_Property** – dotyczy danych, które opisują dane miejsca noclegowe i nieruchomości. Zawiera dużo szczegółowych informacji na temat wynajmowanego miejsca. Są to między innymi informacje o gospodarzu, typie nieruchomości, liczbie pokoi, lokalizacji, średnich opiniach itp.
- **Dim_Weather** – opisuje pogodę dla danej lokalizacji i daty. Przechowuje dane takie jak temperatura, opady, godzina wschodu i zachodu słońca.
- **Dim_Date** – standardowa tabela kalendarza zawierająca dokładne informacje dotyczące daty: dzień tygodnia, miesiąc, kwartał, czy dzień wolny od pracy.

Szczegółowe informacje o bazie danych przedstawione są w tabelach 4.1 - 4.5.

Kolumna	Typ danych	NULL	Relacja
date	date	Nie	PK
Day	tinyint	Nie	
DaySuffix	char(2)	Nie	
Weekday	tinyint	Nie	
WeekDayName	varchar(10)	Nie	
IsWeekend	bit	Nie	
IsHoliday	bit	Nie	

4.2. TABELE WYMIARÓW

DOWInMonth	tinyint	Nie	
DayOfYear	smallint	Nie	
WeekOfMonth	tinyint	Nie	
WeekOfYear	tinyint	Nie	
ISOWeekOfYear	tinyint	Nie	
Month	tinyint	Nie	
MonthName	varchar(10)	Nie	
Quarter	tinyint	Nie	
QuarterName	varchar(6)	Nie	
Year	int	Nie	
MMYYYY	char(6)	Nie	
MonthYear	char(7)	Nie	
FirstDayOfMonth	date	Nie	
LastDayOfMonth	date	Nie	
FirstDayOfQuarter	date	Nie	
LastDayOfQuarter	date	Nie	
FirstDayOfYear	date	Nie	
LastDayOfYear	date	Nie	
HolidayText	nvarchar(100)	Nie	

Tabela 4.1: Dim_Date

Kolumna	Typ danych	NULL	Relacja
property_id	bigint	Nie	PK
last_scraped	date	Nie	
property_name	nvarchar(255)	Nie	
host_id	bigint	Nie	
host_name	nvarchar(100)	Nie	
host_since	date	Nie	
host_response_time	nvarchar(50)	Nie	
host_response_rate	float	Nie	
host_acceptance_rate	float	Nie	
host_is_superhost	nvarchar(3)	Nie	
host_listings_count	int	Nie	

host_total_listings_count	int	Nie	
host_identity_verified	nvarchar(3)	Nie	
latitude	float	Nie	
longitude	float	Nie	
property_type	nvarchar(100)	Nie	
room_type	nvarchar(100)	Nie	
accommodates	int	Nie	
bathrooms	float	Nie	
bedrooms	int	Nie	
beds	int	Nie	
price	float	Nie	
minimum_nights	int	Nie	
maximum_nights	int	Nie	
has_availability	nvarchar(3)	Nie	
availability_30	int	Nie	
availability_60	int	Nie	
availability_90	int	Nie	
availability_365	int	Nie	
number_of_reviews	int	Nie	
number_of_reviews_ltm	int	Nie	
number_of_reviews_l30d	int	Nie	
review_scores_rating	float	Nie	
review_scores_accuracy	float	Nie	
review_scores_cleanliness	float	Nie	
review_scores_checkin	float	Nie	
review_scores_communication	float	Nie	
review_scores_location	float	Nie	
review_scores_value	float	Nie	
instant_bookable	nvarchar(3)	Nie	
calculated_host_listings_count	int	Nie	
calculated_host_listings_count_entire_homes	int	Nie	
calculated_host_listings_count_private_rooms	int	Nie	
calculated_host_listings_count_shared_rooms	int	Nie	
reviews_per_month	float	Nie	

4.2. TABELE WYMIARÓW

scrape_date	int	Nie	
country	nvarchar(100)	Nie	
region	nvarchar(100)	Nie	
city	nvarchar(100)	Nie	

Tabela 4.2: Dim_Property

Kolumna	Typ danych	NULL	Relacja
weather_id	nvarchar(50)	Nie	PK
date	date	Nie	
lcoation_name	nvarchar(100)	Nie	
avg_temp	float	Nie	
max_temp	float	Nie	
min_temp	float	Nie	
daily_will_it_rain	nvarchar(3)	Nie	
daily_will_it_snow	nvarchar(3)	Nie	
daily_chance_of_rain	float	Nie	
daily_chance_of_snow	float	Nie	
sunrise	time(7)	Nie	
sunset	time(7)	Nie	
last_modified_date	date	Nie	

Tabela 4.3: Dim_Weather

Kolumna	Typ danych	NULL	Relacja
offer_id	bigint (IDENTITY)	Nie	PK
property_id	bigint	Nie	FK → Dim_Property(property_id)
offer_date	date	Nie	FK → Dim_Date(date)
available	nvarchar(3)	Nie	
price	money	Nie	
minimum_nights	int	Nie	
maximum_nights	int	Nie	
weather_id	nvarchar(50)	Nie	FK → Dim_Weather(weather_id)
scrape_date	int	Nie	
country	nvarchar(100)	Nie	

region	nvarchar(100)	Nie	
city	nvarchar(100)	Nie	

Tabela 4.4: Fact_Offers

Kolumna	Typ danych	NULL	Relacja
review_id	bigint (IDENTITY)	Nie	PK
property_id	bigint	Nie	FK → Dim_Property(property_id)
date	date	Nie	FK → Dim_Date(date)
reviewer_name	nvarchar(100)	Nie	
reviewer_id	bigint	Nie	
scrape_date	int	Nie	
country	nvarchar(100)	Nie	
region	nvarchar(100)	Nie	
city	nvarchar(100)	Nie	

Tabela 4.5: Fact_Review

5. Kluczowe miary i atrybuty w modelu

Najważniejsze miary wykorzystywane do analiz znajdują się w tabelach faktów, a opisy i atrybuty danych przechowywane są w tabelach wymiarów.

Miary (tabele faktów)

- **Fact _ Offers**
 - `price` – cena oferty w danym dniu,
 - `available` – dostępność oferty,
 - `minimum_nights`, `maximum_nights` – minimalna i maksymalna długość pobytu.
- **Fact _ Review**
 - zagregowana liczba uzyskanych opinii.

Atrybuty (tabele wymiarów)

- **Dim _ Property**
 - `property_type`, `room_type`, `accommodates`, `price`, `bedrooms`, `beds`, `bathrooms` - podstawowe informacje na temat wynajmowanego miejsca,
 - `host_is_superhost`, `host_response_rate` itd. - informacje na temat właściciela obiektu,
 - `latitude`, `longitude`, `country`, `region`, `city` - dane na temat lokalizacji wynajmowanego miejsca,
 - `review_scores_rating`, `reviews_per_month`, itd. - dane dotyczące ocen obiektu.
- **Dim _ Date**

- year, quarter, month, day, is_weekend - te i wiele innych parametrów dotyczących daty.

- **Dim_Weather**

- avg_temp, daily_will_it_rain - te i inne parametry określające pogodę dla danego dnia.

6. Planowane raporty dla użytkowników

Wygenerowano przy użyciu ChatGPT - zwalidowała Natalia Choszczyk.

Na podstawie danych zawartych w hurtowni planowane są następujące raporty:

- **Raport dostępności i cen nieruchomości**
 - Średnia cena noclegu w wybranych miastach i regionach.
 - Zmiany cen w zależności od sezonu (na podstawie `Dim_Date`).
 - Poziom dostępności nieruchomości w danym okresie.
- **Raport efektywności gospodarzy**
 - Średnie oceny gospodarzy (`review_scores_*`),
 - Wskaźniki odpowiedzi i akceptacji rezerwacji.
 - Analiza popularności gospodarzy (liczba recenzji, liczba ofert).
- **Raport recenzji i opinii klientów**
 - Liczba recenzji w czasie – trendy sezonowe.
 - Analiza lokalizacji z największą liczbą opinii.
 - Dynamika liczby recenzji w ujęciu miesięcznym.

7. Planowane testy

Wygenerowano przy użyciu ChatGPT - zwalidował Filip Langiewicz.

W celu zapewnienia poprawności działania modelu planowane są następujące testy:

Testy wydajnościowe

- Czas wykonania zapytań agregujących dane z tabel faktów.
- Wydajność przy łączeniu z tabelami wymiarów o dużej liczbie kolumn (np. `Dim_Property`).
- Testy zapytań filtrujących dane po czasie, lokalizacji i typie oferty.

Testy ETL

- Weryfikacja poprawności załadowanych danych (liczność, zakres dat).
- Testy idempotentności ładowania danych (czy powtórne uruchomienie nie duplikuje rekordów).

Testy Python

- Weryfikacja odporności skryptów pythonowych na napotkane wyjątki.
- Weryfikacja poprawności wypisywania logów do plików.